

Методы Оптимизации. Даниил Меркулов. Векторное дифференцирование.


Базовые понятия

Градиент

Пусть есть функция $f(x) : \mathbb{R}^n \rightarrow \mathbb{R}$, тогда вектор, составленный из частных производных следующим образом:

$$\nabla f(x) = \frac{df}{dx} = \begin{pmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \\ \vdots \\ \frac{\partial f}{\partial x_n} \end{pmatrix}$$

называется градиентом функции $f(x)$. Этот вектор указывает направление наискорейшего возрастания в точке. Стало быть, вектор $-\nabla f(x)$ совпадает с направлением наискорейшего спуска для заданной функции в точке. Кроме того, вектор градиента в конкретной точке всегда перпендикулярен линии уровня функции, содержащей эту точку.



Соответственно,

$$\nabla f(x)^T = \frac{df}{dx^T} = \left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \dots, \frac{\partial f}{\partial x_n} \right)$$

Гессиан

Пусть есть функция $f(x) : \mathbb{R}^n \rightarrow \mathbb{R}$, тогда матрица, составленная из смешанных производных второго порядка следующим образом:

$$f''(x) = \frac{d(\nabla f)}{dx^T} = \frac{d(\nabla f^T)}{dx} = \begin{pmatrix} \frac{\partial^2 f}{\partial x_1 \partial x_1} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_n \partial x_n} \end{pmatrix}$$

называется матрицей Гессе функции $f(x)$ и содержит в себе информацию о кривизне функции многих переменных в точке. Определитель этой матрицы называют гессианом функции $f(x)$ в точке. Эта матрица симметрична в том случае, когда порядок смешанного дифференцирования не важен, т.е. в случае, когда смешанные производные непрерывны.

Широко принято называть гессианом не определитель матрицы Гессе, а саму матрицу, мы будем делать так же:) Положительная (отрицательная) определенность гессиана в точке является достаточным условием локального минимума (максимума) функции в точке.

Обобщением понятия гессиана на случай векторнозначной функции $(f(x) : \mathbb{R}^n \rightarrow \mathbb{R}^m)$ является трехмерный тензор, состоящий из гессианов по каждой компоненте вектор - функции:

$$(H(f_1(x)), H(f_2(x)), \dots, H(f_m(x)))$$

Якобиан

Для функции $f(x) : \mathbb{R}^n \rightarrow \mathbb{R}^m$ вводится понятие матрицы Якоби:

$$f'(x) = \frac{df}{dx^T} = \begin{pmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} & \cdots & \frac{\partial f_1}{\partial x_n} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} & \cdots & \frac{\partial f_2}{\partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_m}{\partial x_1} & \frac{\partial f_m}{\partial x_2} & \cdots & \frac{\partial f_m}{\partial x_n} \end{pmatrix}$$

Если матрица квадратная, то её определитель называют якобианом функции $f(x)$. Часто саму матрицу так же называют якобианом. Если для некоторой функции в точке определитель матрицы Якоби отличен от нуля, то тогда и только тогда в окрестности этой точки существует обратная функция.

Матричное дифференцирование


Сводная таблица

$$f(x) : X \rightarrow Y; \quad \frac{\partial f(x)}{\partial x} \in G$$

X	Y	G	Обозначение
\mathbb{R}	\mathbb{R}	\mathbb{R}	$f'(x)$ (производная)
\mathbb{R}^n	\mathbb{R}	\mathbb{R}^n	$\frac{\partial f}{\partial x_i}$ (градиент)
\mathbb{R}^n	\mathbb{R}^m	$\mathbb{R}^{n \times m}$	$\frac{\partial f_i}{\partial x_j}$ (якобиан)
$\mathbb{R}^{m \times n}$	\mathbb{R}	$\mathbb{R}^{m \times n}$	$\frac{\partial f}{\partial x_{ij}}$

Общая схема

Ожидание



Дифференцирование сложной функции

- Пусть $x \in \mathbb{R}^n$; $g: \mathbb{R}^n \rightarrow \mathbb{R}^p$; $f: \mathbb{R}^p \rightarrow \mathbb{R}^1$

$$\frac{\partial f(g(x))}{\frac{\partial x_j}{n \times 1}} = \sum_{i=1}^p \frac{\partial f}{\partial g_i} \cdot \frac{\partial g_i}{\partial x_j} = \frac{\partial g^T}{\frac{\partial x_j}{n \times p}} \cdot \frac{\partial f}{\frac{\partial g}{p \times 1}}$$

- Для векторнозначной функции: пусть $x \in \mathbb{R}^n$; $g: \mathbb{R}^n \rightarrow \mathbb{R}^p$; $f: \mathbb{R}^p \rightarrow \mathbb{R}^m$

$$\frac{\partial f(g(x))}{\frac{\partial x^T}{m \times n}} = \frac{\partial f}{\frac{\partial g^T}{m \times p}} \cdot \frac{\partial g}{\frac{\partial x^T}{p \times n}}$$

- Стало быть для $p = 1$: $x \in \mathbb{R}^n$; $g: \mathbb{R}^n \rightarrow \mathbb{R}^1$; $f: \mathbb{R}^1 \rightarrow \mathbb{R}^m$

$$\frac{\partial f(g(x))}{\frac{\partial x^T}{m \times n}} = \frac{\partial f}{\frac{\partial g}{m \times 1}} \cdot \frac{\partial g}{\frac{\partial x^T}{1 \times n}}$$

- Еще один важный случай: $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$; $\alpha: \mathbb{R}^n \rightarrow \mathbb{R}^1$

$$\frac{d(\alpha(x)f(x))}{\frac{dx^T}{m \times n}} = \alpha(x) \frac{df}{\frac{dx^T}{m \times n}} + f(x) \frac{d\alpha(x)}{\frac{dx^T}{1 \times n}}$$

Примеры

Пример 1

Найти $\nabla f(x)$, если $f(x) = c^T x$

Решение:

- $f(x) = \sum_{i=1}^n c_i x_i$
- $\frac{\partial f(x)}{\partial x_i} = c_i \rightarrow \nabla f(x) = c$

Пример 2

Найти $\nabla f(x)$, если $f(x) = \frac{1}{2} x^T A x + b^T x + c$

Решение:

- $f(x) = \sum_{i=1}^n \left[\frac{1}{2} x_i \left(\sum_{j=1}^n a_{ij} x_j \right) + b_i x_i + c_i \right] = \frac{1}{2} \sum_{i,j=1}^n [x_i a_{ij} x_j] + \sum_{i=1}^n b_i x_i + c_i$
- $\frac{\partial f(x)}{\partial x_i} = \frac{1}{2} \sum_{j=1}^n (a_{ij} + a_{ji}) x_j + b_i \rightarrow \nabla f(x) = \frac{1}{2} (A + A^T) x + b$

Пример 3

Найти градиент билинейной формы $f(x) = u^T(x) R v(x)$,
 $R \in \mathbb{R}^{m \times p}$; $u(x): \mathbb{R}^n \rightarrow \mathbb{R}^m$; $v(x): \mathbb{R}^n \rightarrow \mathbb{R}^p$

Решение:

$$\frac{d(u^T R v)}{dx} = \frac{du^T}{dx} \left(\frac{\partial (u^T R v)}{\partial u} \right) + \frac{dv^T}{dx} \left(\frac{\partial (u^T R v)}{\partial v} \right) = \frac{du^T}{dx} R v + \frac{dv^T}{dx} R^T u$$

Пример 4

Найти $\nabla f(x)$, если $f(x) = \frac{1}{2} \|Ax - b\|^2$

Решение:

Задачу можно решить двумя различными способами: как композицию функций

$f(x) = \frac{1}{2}\|x\|^2$; $g(x) = Ax - b$, а так же классическим способом, рассмотрев скалярное представление функции.

Ответ: $\nabla f(x) = A^T(Ax - b)$

Пример 5

Найти $\nabla f(x)$, $f''(x)$, если $f(x) = -e^{-x^T x}$

Решение:

- Заметим, что задачу можно решить используя формулу для вычисления градиента сложной функции, однако мы, по старинке, распишем скалярный вид:

$$f(x) = -e^{-\sum_i x_i^2}$$

- Аккуратно посчитаем одну из компонент градиента:

$$\frac{\partial f(x)}{\partial x_k} = -e^{-\sum_i x_i^2} \cdot \left(\frac{\partial(-\sum_i x_i^2)}{\partial x_k} \right) = e^{-\sum_i x_i^2} \cdot 2x_k$$

Значит, вектор градиента запишется, как: $\nabla f(x) = 2e^{-x^T x} \cdot x$

- Абсолютно по такой же логике посчитаем элемент гессиана. Обратите внимание на индексы! Типичная ошибка (недопонимание) здесь возникает, когда записывается везде i, j , бездумно повторяя индексы

$$g_k = \frac{\partial f(x)}{\partial x_k} \rightarrow H_{k,p} = \frac{\partial g_k}{\partial x_p}$$

$$H_{k,p} = - \left(e^{-\sum_i x_i^2} \cdot 2x_p \right) 2x_k + 2e^{-\sum_i x_i^2} \frac{\partial x_k}{\partial x_p} = 2e^{-\sum_i x_i^2} \cdot \left(\frac{\partial x_k}{\partial x_p} - 2x_p x_k \right)$$

- Итого: $f''(x) = H_{f(x)} = 2e^{-x^T x} (E - 2xx^T)$

Пример 6

Найти $f'(X)$, если $f(X) = \log \det X$; $X \in S_{++}^n$ - положительно определенная симметричная квадратная матрица

Решение:

- Применим хитрый трюк и вспомним об еще одном предназначении градиента и производной - линейная аппроксимация функции в окрестности точки.

Заметим, что:

$$\begin{aligned}
\log \det [X + \Delta X] &= \log \det \left[X^{1/2} \left(I + X^{-1/2} \Delta X X^{-1/2} \right) X^{1/2} \right] = \\
&= \log \det \left[X^{1/2} \right] \det \left[I + X^{-1/2} \Delta X X^{-1/2} \right] \det \left[X^{1/2} \right] = \\
&= \log \det [X] \det \left[I + X^{-1/2} \Delta X X^{-1/2} \right] = \log \det [X] + \log \det \left[I + X^{-1/2} \Delta X X^{-1/2} \right]
\end{aligned}$$

- Вспомним так же про то, что определитель матрицы равен произведению её собственных значений

$$\log \det [X + \Delta X] = \log \det X + \sum_{i=1}^n \log(1 + \lambda_i)$$

1 Здесь λ_i - собственные числа матрицы $X^{-1/2} \Delta X X^{-1/2}$. Далее используем факт "малости" матрицы ΔX (в смысле малости нормы этой матрицы), а стало быть, для приближения первого порядка справедливо: $\log(1 + \lambda_i) \approx \lambda_i$ т.к. λ_i так же должны быть малы.

$$\log \det [X + \Delta X] \approx \log \det X + \sum_{i=1}^n \lambda_i$$

$$\begin{aligned}
\log \det [X + \Delta X] &\approx \log \det X + \text{tr} \left[X^{-1/2} \Delta X X^{-1/2} \right] = \\
&= \log \det X + \text{tr} \left[X^{-1/2} X^{-1/2} \Delta X \right] = \log \det X + \text{tr} [X^{-1} \Delta X]
\end{aligned}$$

Заметим, что в пространстве матриц роль скалярного произведения играет именно след их произведения: $\text{tr}(A^T B) = \text{tr}(AB^T) = \text{tr}(B^T A) = \text{tr}(BA^T)$. Стало быть, имеем:


$$f(X + \Delta X) \approx f(X) + \langle X^{-1}, \Delta X \rangle$$

$$f(X + \Delta X) \approx f(X) + \langle f'(X), \Delta X \rangle$$

Значит, $f'(X) = X^{-1}$

Пример 7

Обучение



Рассмотрим упрощенную задачу обучения с помощью линейной модели (однослойной нейронной сети). Для этого необходимо подобрать параметры полносвязного слоя $W \in \mathbb{R}^{c \times n}$, $b \in \mathbb{R}^c$ так, чтобы минимизировать функцию потерь (невязку). Для этого часто используют градиентные методы. Т.е. схема оптимизационных алгоритмов идейно следующая:

$$b_{k+1} = b_k - \beta \frac{\partial L(x, y, W_k, b_k)}{\partial b^T}$$

$$W_{k+1} = W_k - \omega \frac{\partial L(x, y, W_k, b_k)}{\partial W}$$

Здесь частные производные считаются именно по параметрам W, b , а не по аргументу x , а β, ω - заданные константы.

Посчитайте $\frac{\partial L(x, y, W, b)}{\partial b^T}$ и $\frac{\partial L(x, y, W, b)}{\partial W}$

Решение:

- $L(x, y, W, b) = \frac{1}{2} \sum_{i=1}^c \left(\sum_{j=1}^n (w_{ij} x_j) + b_i - y_i \right)^2$
- $\frac{\partial L(x, y, W, b)}{\partial b_p} = \frac{1}{2} 2 \sum_{i=1}^c \left(\sum_{j=1}^n (w_{ij} x_j) + b_i - y_i \right) \cdot \frac{\partial b_i}{\partial b_p} = \sum_{j=1}^n (w_{pj} x_j) + b_p - y_p$
- Значит, $\frac{\partial L(x, y, W, b)}{\partial b^T} = Wx + b - y$
- Не забываем про главный секрет векторного дифференцирования: наличие, как минимум, латинского алфавита для индексов:

$$\frac{\partial L(x, y, W, b)}{\partial w_{rs}} = \frac{1}{2} 2 \sum_{i=1}^c \left(\sum_{j=1}^n (w_{ij} x_j) + b_i - y_i \right) \cdot \frac{\partial \sum_{j=1}^n (w_{ij} x_j)}{\partial w_{rs}}$$

$$\frac{\partial L(x, y, W, b)}{\partial w_{rs}} = \left(\sum_{j=1}^n (w_{rj} x_j) + b_r - y_r \right) \cdot x_s$$

$$\frac{\partial L(x, y, W, b)}{\partial w_{rs}} = \sum_{j=1}^n (w_{rj} x_j x_s) + b_r x_s - y_r x_s$$

- Значит, $\frac{\partial L(x, y, W, b)}{\partial W} = Wxx^T + (b - y)x^T$

Домашнее задание 5

1. Найти $\nabla f(x)$, если $f(x) = Ax - x^T A$
2. Найти $\nabla f(x), f''(x)$, если $f(x) = \frac{-1}{1 + x^T x}$
3. Найти $f'(X)$, если $f(X) = \det X$
4. Найти $f''(X)$, если $f(X) = \log \det X$
5. Найти градиент и гессиан функции $f: \mathbb{R}^n \rightarrow \mathbb{R}$,

$$f(x) = \log \sum_{i=1}^m \exp(a_i^T x + b_i), \quad a_1, \dots, a_m \in \mathbb{R}^n; \quad b_1, \dots, b_m \in \mathbb{R}$$